

Universidad Nacional de Ingeniería
Facultad de Ciencias

Arquitectura de computadores

Multinúcleos, Multiprocesadores y Clústeres

Prof.: Lic. César Martín Cruz S.
ccruz@uni.edu.pe

Introducción

- **Objetivo:** Conectar múltiples computadoras para obtener un rendimiento más alto.
 - Multiprocesadores
 - Escalabilidad, disponibilidad, eficiencia de energía.
 - Programa de procesamiento paralelo
 - Se ejecuta un único programa sobre múltiples procesadores.
 - Microprocesadores multinúcleos
 - Microprocesador que contiene varios procesadores (núcleos) en el mismo circuito integrado.
 - Clúster, es un conjunto de computadores conectados con una red de área local(LAN) que opera como un único multiprocesador.

Hardware y Software

- **Hardware**

- Serie: Por ejemplo, Pentium 4
- Paralelo: Por ejemplo, quad-core Xeon E5345

- **Software**

- Secuencial: Por ejemplo, multiplicación de matrices en Matlab
- Concurrente: Por ejemplo, sistema operativo Windows Vista
- Software secuencial/concurrente puede correr sobre hardware serie/paralelo
 - Desafío: hacer un uso efectivo de hardware en paralelo

Programación Paralela

- La dificultad del paralelismo no está en el hardware. El software paralelo es el problema
- Se necesita obtener una mejora de rendimiento significativo en el software
 - De otra manera, sólo se utiliza un monoprocesador más rápido desde que es más fácil!
- Dificultades
 - Particionamiento
 - Coordinación (tiempo de sincronización)
 - Sobrecarga de las comunicaciones entre colaboradores


Ley de Amdahl

- Evalúa como cambia el rendimiento al mejorar una parte de la computadora.
- Define el ***speedup*** (aceleración) que se puede alcanzar al usar cierta mejora.

$$\text{Speedup} = \frac{\text{Tiempo de ejecución sin la mejora}}{\text{Tiempo de ejecución con la mejora}}$$

Memoria compartida

- SMP: Multiprocesador de memoria compartida
 - El hardware suministra un espacio único de direcciones físicas para todos los procesadores
 - Sincroniza variables compartidas usando bloqueos
 - Tiempo de acceso de memoria
 - UMA(uniforme) vs. NUMA(nounifome)



UMA vs. NUMA

Hay dos tipos de multiprocesadores con espacio de direcciones único.

- UMA (Uniform Memory Access) *Acceso a memoria uniforme*
 - Todos los accesos a memoria tardan el mismo tiempo.
- NUMA (Non-uniform Memory Access) *Acceso a memoria no uniforme*
 - Algunos accesos a memoria son más rápidos que otros, dependiendo de qué procesador quiere acceder a que palabra.

Ejemplo: Suma con reducción

- Se quiere sumar 100,000 números sobre 100 procesadores UMA
 - Cada procesador tiene ID: $0 \leq P_n \leq 99$
 - Partición de 1000 números por procesador
 - Suma inicial en cada procesador

```
sum[Pn] = 0;
```

```
for (i = 1000*Pn; i < 1000*(Pn+1); i = i + 1)  
    sum[Pn] = sum[Pn] + i;
```


- Ahora, necesitamos sumar estas sumas parciales. Esta acción se llama ***reducción(divide y venceras)***

Los clústeres

- **Red de computadoras independientes**
 - Cada uno tiene memoria privada y un SO(Sistema Operativo)
 - Conectado vía los puertos de E/S
 - Por ejemplo, Ethernet/switch, Internet
- **Apto para aplicaciones con tareas independientes**
 - Servidores Web, bases de datos, simulaciones, ...
- **Es escalable, asequible**
- **Problemas**
 - El costo de administración.
 - Menor ancho de banda de interconexión.

Clústeres y otros de paso de mensaje(memoria distribuida)

- Cada procesador tiene un espacio de direcciones físicas privado.
- Envío/recepción de mensajes entre procesadores.



Procesador Superescalar

- El término “superescalar” (superscalar) fue acuñado a fines de los 80s.
- Todas las CPUs modernas son superescalares.
- Es un desarrollo de la arquitectura con pipeline(segmentación).
- Se generan nuevos peligros por dependencias.

Procesador Superescalar

- Este procesador emplea una técnica avanzada de segmentación que le *permite ejecutar más de una instrucción por ciclo de reloj*. Para alcanzar buenas prestaciones en este procesador, se requiere que el compilador planifique las instrucciones de forma que se eliminen dependencias y se mejore la frecuencia de ejecución.

Procesador Superescalar

- Al emitir varias instrucciones por ciclo el CPI (ciclos por instrucción) es menor a 1.
- Una CPU de 6 GHz que emite 4 instrucciones a la vez puede ejecutar hasta 24 mil millones de instrucciones por segundo para un CPI de 0.25.
- En vez de CPI se usa IPC (instrucciones por ciclo de reloj) = $1 / \text{CPI}$.
- Un CPI de 0.25 es igual a un IPC de 4.

EPIC

Procesamiento de instrucciones explícitamente en paralelo (del inglés EPIC: Explicitly Parallel Instruction Computing) es un paradigma de programación que comenzó a investigarse a principios de los años 80 y se convirtió en una patente estadounidense 4,847,755 (Gordon Morrison, et. al). Este paradigma también se conoce como arquitecturas de Independencia. Fue utilizado por Intel y HP para el desarrollo de la arquitectura de Intel IA-64 y se ha implementado en la línea de procesadores de servidor Intel Itanium e Itanium 2. El objetivo de EPIC era aumentar la capacidad de los microprocesadores para ejecutar instrucciones de software en paralelo mediante el uso del compilador, en lugar de la compleja circuitería.

Multihilo en hardware (Multithreading)

- Realización de múltiples hilos de ejecución en paralelo. Permite que varios hilos(*threads*) compartan *las unidades funcionales del procesador* y se ejecuten simultáneamente
 - Cada hilo tiene una copia del banco de registros, el PC, etc.
 - Rápida conmutación de la ejecución entre diferentes hilos
- Dos alternativas para la ejecución multihilo en hardware
 - Ejecución multihilo de *grano fino(FMT)*, se cambia de hilo en cada instrucción, y como resultado se obtiene una ejecución entrelazada de varios hilos.
 - La ejecución multihilo de *grano grueso(CMT)*,

Procesadores Vectoriales

- Es un procesador capaz de ejecutar operaciones matemáticas sobre múltiples datos de forma simultánea, en contraste con los procesadores escalares, capaces de manejar sólo un dato cada vez. Los procesadores vectoriales proporcionan operaciones de alto nivel que trabajan sobre vectores. Segmentan las operaciones sobre los elementos de un vector, tanto la operación aritmética como los accesos a memoria.

Procesadores Vectoriales

- Una característica clave es un conjunto de registros vectoriales para sostener los operandos y resultados. Recolecta los datos de memoria, los pone en orden en un gran conjunto de registros, los opera secuencialmente en registros, y luego escribe los resultados de regreso a memoria.
- Ellos formaron la base de las supercomputadoras en los 80s y los 90s.

Procesadores Vectoriales

- La extensión del conjunto de instrucciones de MIPS(VMIPS) incluye instrucciones vectoriales, por ejemplo:
- 32 registros de 64 elementos de 64 bits cada elemento
- Addv.d para sumar dos vectores de precisión doble.
- Addvs.d y mulvs.d para sumar(o multiplicar) un registro escalar a cada elemento dentro de un registro vectorial.
- Lv y sv hacen carga vectorial y almacenaje vectorial de un vector entero de doble precisión de datos.

Unidades de procesamiento gráfico(GPUs)


- La industria de los juegos por computador, tanto en PCs como en consolas como la Sony PlayStation, fue una fuerza motriz decisiva para la mejora del procesamiento gráfico.

A medida que los procesadores gráficos aumentaban en potencia, se ganaron el nombre de Unidades de procesamiento gráfico (*Graphics Processing Units*) o *GPUs*, para distinguirse de las CPUs.

Características de las GPUs

- Las GPUs son aceleradores que complementan a la CPU, no realizan todas las funciones de la CPU. No importa esto ya que en un sistema GPU y CPU, la CPU puede hacer todo lo que la GPU no puede. Así, la combinación CPU-GPU es un ejemplo de *multiprocesamiento heterogéneo*, donde los procesadores no tienen por qué ser iguales
- La interfaz de programación de las GPUs que están libres de restricciones de compatibilidad con versiones anteriores resultan en una más rápida innovación en la GPU que en la CPU.
- Los tipos de datos de gráficos son vértices, que constan de las coordenadas (x, y, z, w), y píxeles, que constan de componentes de color (rojo, verde, azul, alfa).

Procesamiento gráfico en el computador



Arquitectura de la GPU

- El procesamiento de datos es altamente paralelo
 - Las GPU utilizan ejecución multihilos a gran escala
 - Utiliza la conmutación a hilos para ocultar la latencia de memoria
 - Menos dependencia de los caches multinivel
 - La memoria gráfica es amplia y de alto ancho de banda
- Tendencia hacia la GPU de propósito general
 - CPU para el código secuencial, GPU para código paralelo
- Lenguajes de programación/APIs
 - DirectX, OpenGL
 - C para Gráficos (Cg), High Level Shader Language (HLSL)
 - Compute Unified Device Architecture (CUDA) de NVIDIA

Conclusión

- **Objetivo**: Obtener mayor rendimiento mediante el uso de múltiples procesadores
- Dificultades
 - El desarrollo de software paralelo
 - La elaboración de arquitecturas adecuadas
- Muchas razones para ser optimistas
 - Evolución del entorno de software y aplicaciones
 - Multiprocesadores a nivel de chip con menor latencia, mayor ancho de banda de interconexión
- **Es un desafío permanente para los arquitectos de los computadores!**